

**Московский государственный технический
университет им. Н. Э. Баумана**

Курс «Технологии машинного обучения»

Отчёт по рубежному контролю №1

«Технологии разведочного анализа и обработки данных.»

Вариант № 12

Выполнил:
Коренева С.А.
группа ИУ5-63Б

Проверил:
Гапанюк Ю.Е.

Дата: 11.04.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Задание:

Номер варианта: **12**

Номер задачи: **2**

Номер набора данных, указанного в задаче: **4**

(<https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>)

Для студентов групп ИУ5-63Б, ИУ5Ц-83Б - для произвольной колонки данных построить график "Ящик с усами (boxplot)".

Задача №2.

Для заданного набора данных проведите обработку пропусков в данных для одного категориального и одного количественного признака. Какие способы обработки пропусков в данных для категориальных и количественных признаков Вы использовали? Какие признаки Вы будете использовать для дальнейшего построения моделей машинного обучения и почему?

Ход выполнения:

1) Загрузила набор данных.

```
[1]: import pandas as pd
import numpy as np

[4]: df = pd.read_csv('heart.csv')
df.columns = df.columns.str.strip()
df.head()
```

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak	slope	ca	thal	target
0	52	1	0	125	212	0	1	168	0	1.0	2	2	3	0
1	53	1	0	140	203	1	0	155	1	3.1	0	0	3	0
2	70	1	0	145	174	0	1	125	1	2.6	0	0	3	0
3	61	1	0	148	203	0	1	161	0	0.0	2	1	3	0
4	62	0	0	138	294	1	1	106	0	1.9	1	3	2	0

2) Было выяснено, что данные не имеют пропусков.

```
[5]: df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1025 entries, 0 to 1024
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype  
---  --
0   age         1025 non-null  int64  
1   sex         1025 non-null  int64  
2   cp          1025 non-null  int64  
3   trestbps    1025 non-null  int64  
4   chol        1025 non-null  int64  
5   fbs         1025 non-null  int64  
6   restecg     1025 non-null  int64  
7   thalach     1025 non-null  int64  
8   exang       1025 non-null  int64  
9   oldpeak     1025 non-null  float64 
10  slope       1025 non-null  int64  
11  ca          1025 non-null  int64  
12  thal        1025 non-null  int64  
13  target      1025 non-null  int64  
dtypes: float64(1), int64(13)
memory usage: 112.2 KB

[6]: print(df.isnull().sum())

age         0
sex         0
cp          0
trestbps    0
chol        0
fbs         0
restecg     0
thalach     0
exang       0
oldpeak     0
slope       0
ca          0
thal        0
target      0
dtype: int64
```

3) Наш датасет не имеет пропущенных значений. Для выполнения поставленной задачи создадим пропуски искусственно.

Для начала сделаем атрибут thal категориальным.

```
[36]: thal_map = {
        0: 'not defined',
        1: 'normal',
        2: 'fixed defect',
        3: 'reversible defect'
    }
df['thal'] = df['thal'].map(thal_map)
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1025 entries, 0 to 1024
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype  
---  --
0   age         1025 non-null  int64  
1   sex         1025 non-null  int64  
2   cp          1025 non-null  int64  
3   trestbps    1025 non-null  int64  
4   chol        1025 non-null  int64  
5   fbs         1025 non-null  int64  
6   restecg     1025 non-null  int64  
7   thalach     1025 non-null  int64  
8   exang       1025 non-null  int64  
9   oldpeak     1025 non-null  float64 
10  slope       1025 non-null  int64  
11  ca          1025 non-null  int64  
12  thal        1025 non-null  object  
13  target      1025 non-null  int64  
dtypes: float64(1), int64(12), object(1)
memory usage: 112.2+ KB
```

Создадим 5% пропусков для колонок trestbps и thal.

```
[38]: for col in ['trestbps', 'thal']:
      missing_indices = df.sample(frac=0.05, random_state=52).index
      df.loc[missing_indices, col] = np.nan
```

```
[39]: df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1025 entries, 0 to 1024
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  -
0    age         1025 non-null   int64
1    sex         1025 non-null   int64
2    cp          1025 non-null   int64
3    trestbps     974 non-null    float64
4    chol        1025 non-null   int64
5    fbs         1025 non-null   int64
6    restecg     1025 non-null   int64
7    thalach     1025 non-null   int64
8    exang       1025 non-null   int64
9    oldpeak     1025 non-null   float64
10   slope       1025 non-null   int64
11   ca          1025 non-null   int64
12   thal        974 non-null    object
13   target      1025 non-null   int64
dtypes: float64(2), int64(11), object(1)
memory usage: 112.2+ KB
```

4) Заменяем пропуски в ‘trestbps’ отсеченным средним.

```
[40]: q_05 = df['trestbps'].dropna().quantile(0.05)
      q_95 = df['trestbps'].dropna().quantile(0.95)
      print(f"5-й перцентиль (q_05): {q_05}")
      print(f"95-й перцентиль (q_95): {q_95}")
      filtr_data = df[(df['trestbps'] > q_05) & (df['trestbps'] < q_95)]['trestbps']
      print(f"Количество значений между 5% и 95% квантилями: {len(filtr_data)}")
      filtr_data_mean = filtr_data.mean()
      print(f"Отсеченное среднее для trestbps: {filtr_data_mean}")
      df['trestbps'] = df['trestbps'].fillna(filtr_data_mean)
```

```
5-й перцентиль (q_05): 108.0
95-й перцентиль (q_95): 164.0
Количество значений между 5% и 95% квантилями: 862
Отсеченное среднее для trestbps: 131.02552204176334
```

5) Заменяем пропуски в ‘thal’ модой.

```
[44]: mode_rating = df['thal'].mode()[0]
      print(f"Мода для thal: {mode_rating}")
      df['thal'] = df['thal'].fillna(mode_rating)
```


```
Мода для thal: fixed defect
```

```
[45]: df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1025 entries, 0 to 1024
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  -
0    age         1025 non-null   int64
1    sex         1025 non-null   int64
2    cp          1025 non-null   int64
3    trestbps     1025 non-null   float64
4    chol        1025 non-null   int64
5    fbs         1025 non-null   int64
6    restecg     1025 non-null   int64
7    thalach     1025 non-null   int64
8    exang       1025 non-null   int64
9    oldpeak     1025 non-null   float64
10   slope       1025 non-null   int64
11   ca          1025 non-null   int64
12   thal        1025 non-null   object
13   target      1025 non-null   int64
dtypes: float64(2), int64(11), object(1)
memory usage: 112.2+ KB
```

6) Построим Boxplot для age.

```
[46]: import matplotlib.pyplot as plt
import seaborn as sns
plt.figure(figsize=(8, 6))
sns.boxplot(y=df['age'])
plt.title('Распределение')
plt.ylabel('Возраст')
plt.show()
```



Далее для построения моделей машинного обучения я буду использовать все признаки, так как при работе с болезнями сердца важно учитывать все признаки, а необходимые данные числовые, не имеют пропусков и подходят для работы,